## **SPRAWOZDANIE**

Zajęcia: Matematyka Konkretna

Prowadzący: prof. dr hab. Vasyl Martsenyuk

Laboratorium Nr 4
Data 12.04.2025
Informatyka
Temat: "Funkcje aktywacji w sieciach
neuronowych"
Variant 11
Anna Więzik
Informatyka
II stopień, niestacjonarne,
2 semestr, gr.1a TTO

## 1. Polecenie:

Link do repozytorium: <a href="https://github.com/AnaShiro/MK">https://github.com/AnaShiro/MK</a> 2025

Celem zadania było zbudowanie modeli uczenia maszynowego przy użyciu biblioteki Spark MLlib w celu przewidywania odpływu klientów banku na podstawie rzeczywistych danych. W ramach realizacji celu przeprowadzono pełny proces analityczny, począwszy od wczytania i przygotowania danych, przez eksplorację oraz ekstrakcję cech, aż po budowę i ocenę różnych modeli, takich jak regresja liniowa, Kmeans, drzewa decyzyjne i lasy losowe. Zastosowano również pipeline'y do automatyzacji przetwarzania danych i trenowania modeli oraz przeprowadzono strojenie hiperparametrów z użyciem walidacji krzyżowej.

## 2. Opis programu opracowanego

```
import numpy as np
import matplotlib.pyplot as plt

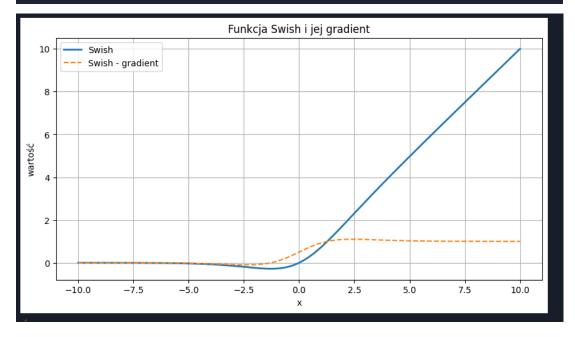
def sigmoid(x):
    return 1 / (1 + np.exp(-x))

def swish(x):
    return x * sigmoid(x)

def swish_grad(x):
    sig = sigmoid(x)
    return sig + x * sig * (1 - sig)

x = np.linspace(-10, 10, 500)
    y = swish(x)
    dy = swish_grad(x)

plt.figure(figsize=(10, 5))
    plt.plot(x, y, label="Swish", linewidth=2)
    plt.plot(x, dy, label="Swish - gradient", linestyle='--')
    plt.title("Funkcja Swish i jej gradient")
    plt.ylabel("x")
    plt.ylabel("wartość")
    plt.grid(True)
    plt.legend()
    plt.show()
```



## 3. Wnioski

Na podstawie przeprowadzonych działań można wyciągnąć kilka wniosków. Przede wszystkim Spark MLlib okazał się skutecznym narzędziem do pracy z dużymi zbiorami danych i umożliwił sprawne tworzenie oraz testowanie modeli uczenia maszynowego. Użycie pipeline'ów znacząco uprościło proces przygotowania danych i trenowania modeli, a walidacja krzyżowa oraz tuning parametrów poprawiły jakość wyników. Modele klasyfikacyjne, takie jak drzewa decyzyjne i lasy losowe, umożliwiły przewidywanie, którzy klienci mogą opuścić bank, co może wspierać działania biznesowe związane z utrzymaniem klientów.